Apprentissage Automatique
Arbres de décision & méthodes ensemblistes

S. Herbin

stephane.herbin@onera.fr

Rappel du dernier cours

- Principes généraux d'apprentissage : données apprentissage/validation/test, optimisation, évaluation
- Deux algorithmes élémentaires de *classification supervisée* : plus proche voisin, classifieur Bayésien

Objectifs de ce cours

- Un nouveau type de classifieur : l'arbre de décision
- Un principe de conception : les approches ensemblistes
  Intuition : « un groupe prend plus souvent de meilleures décisions qu'un individu »

Jeux de déduction

➠ Quelle meilleure question poser ? (Comment fait https://fr.akinator.com/ ?)

Classification hiérarchique

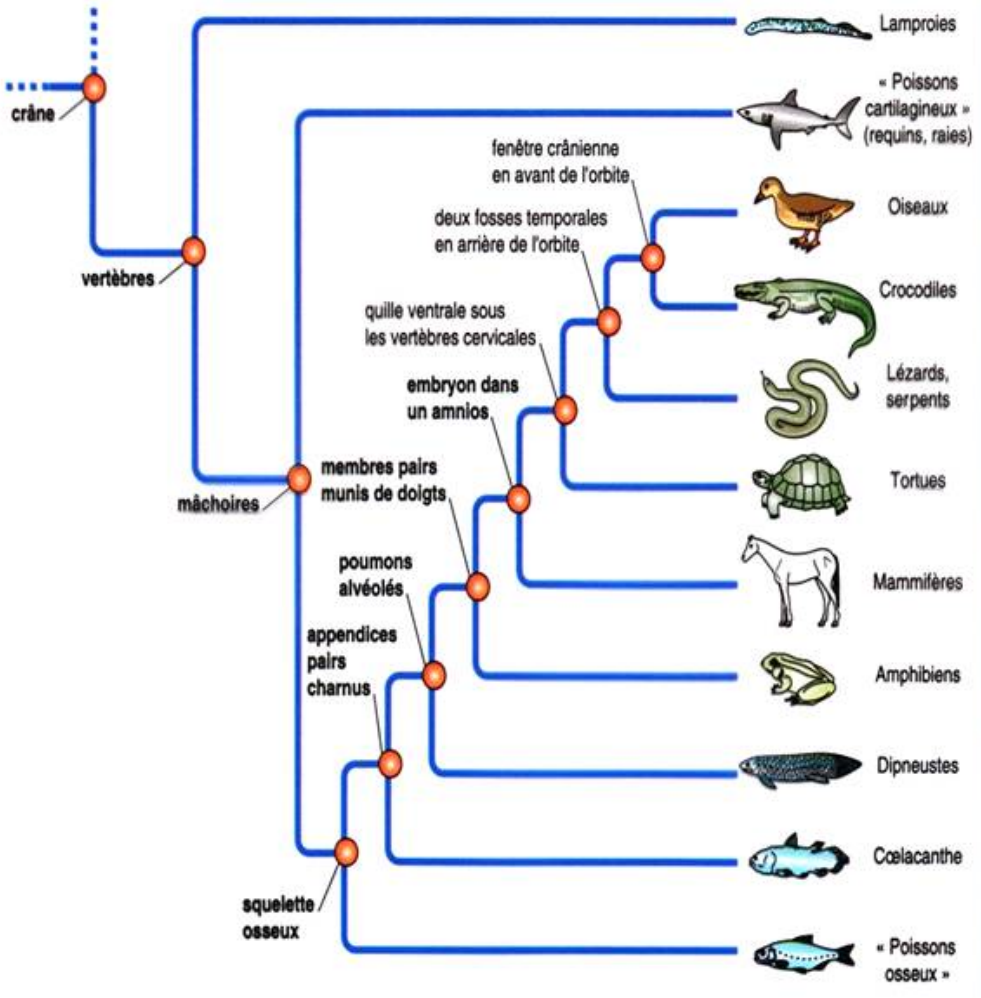

Choisir ma photo de profil

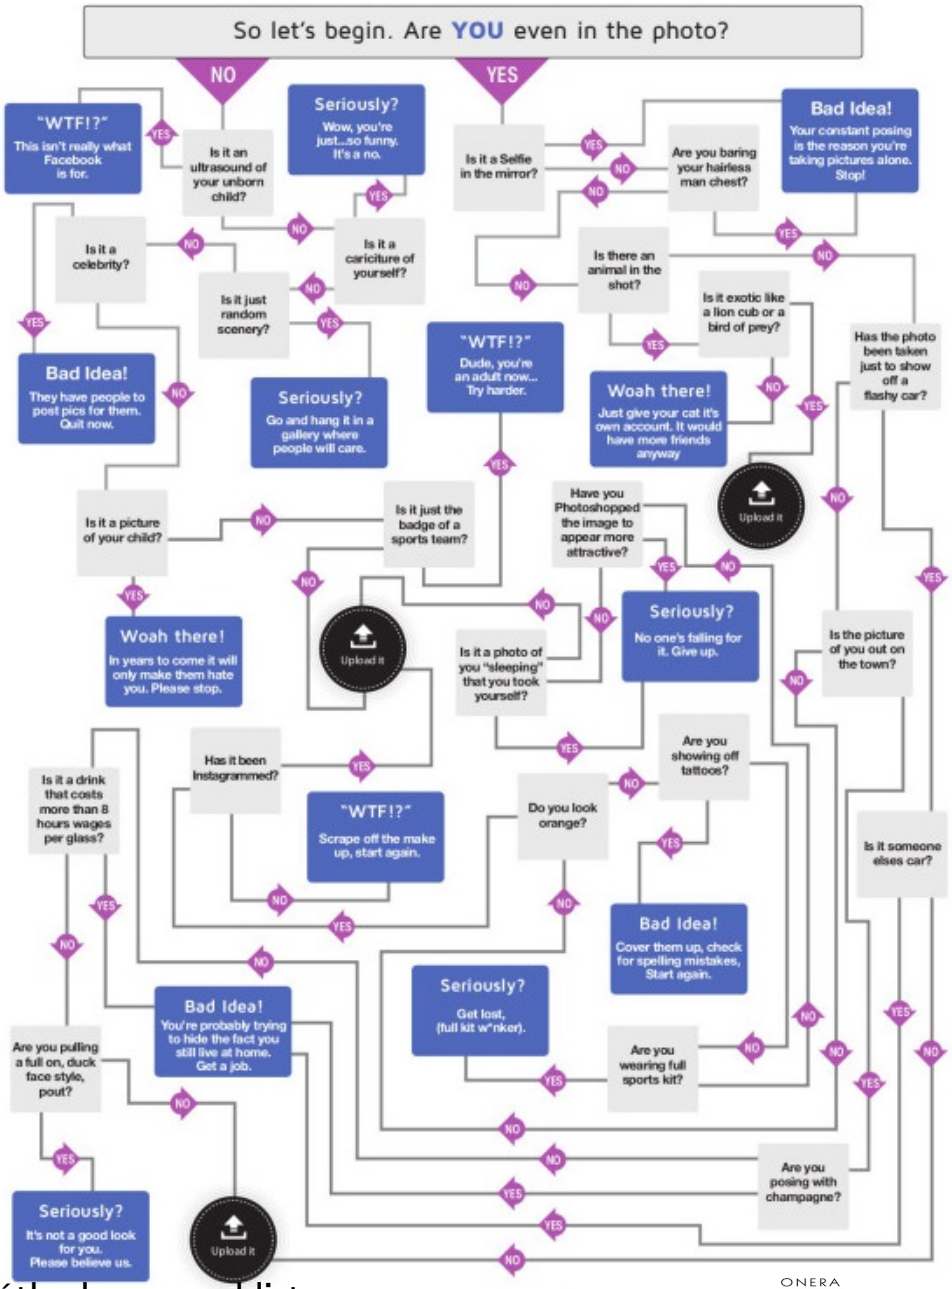

Analyse préliminaire

Qu'y a-t-il de commun à ces exemples ?

- Décompose une prédiction globale en une **séquence** de **décisions** (questions+réponses) locales pour
- **sélectionner** une prédiction pré-estimée.

Les séquences de décisions peuvent être représentées globalement par un **arbre de décision**.

➠ La question du jour : comment construire les séquences de décision (l'arbre) pour une bonne prédiction ?

Arbres de décision [3, 9]

Principe

- Prédiction en posant une séquence de questions fermées (= nombre fini de réponses possibles)
- Questions organisées sous forme d'arbre : la question suivante dépend de la réponse à la question précédente

Types de questions

- Sur la valeur d'un attribut caractéristique : « x est rouge ? »
- Sur la véracité d'une clause logique : $\mathit{rouge}(x) \wedge \mathit{rond}(x) = \texttt{True}$?
- Sur l'appartenance à un intervalle ou un sous-ensemble : $1_{x>0.5}$

Prédiction

- Estimation de la valeur prédite à partir des données pour lesquelles la séquence de questions est vraie

Exemple d'arbre

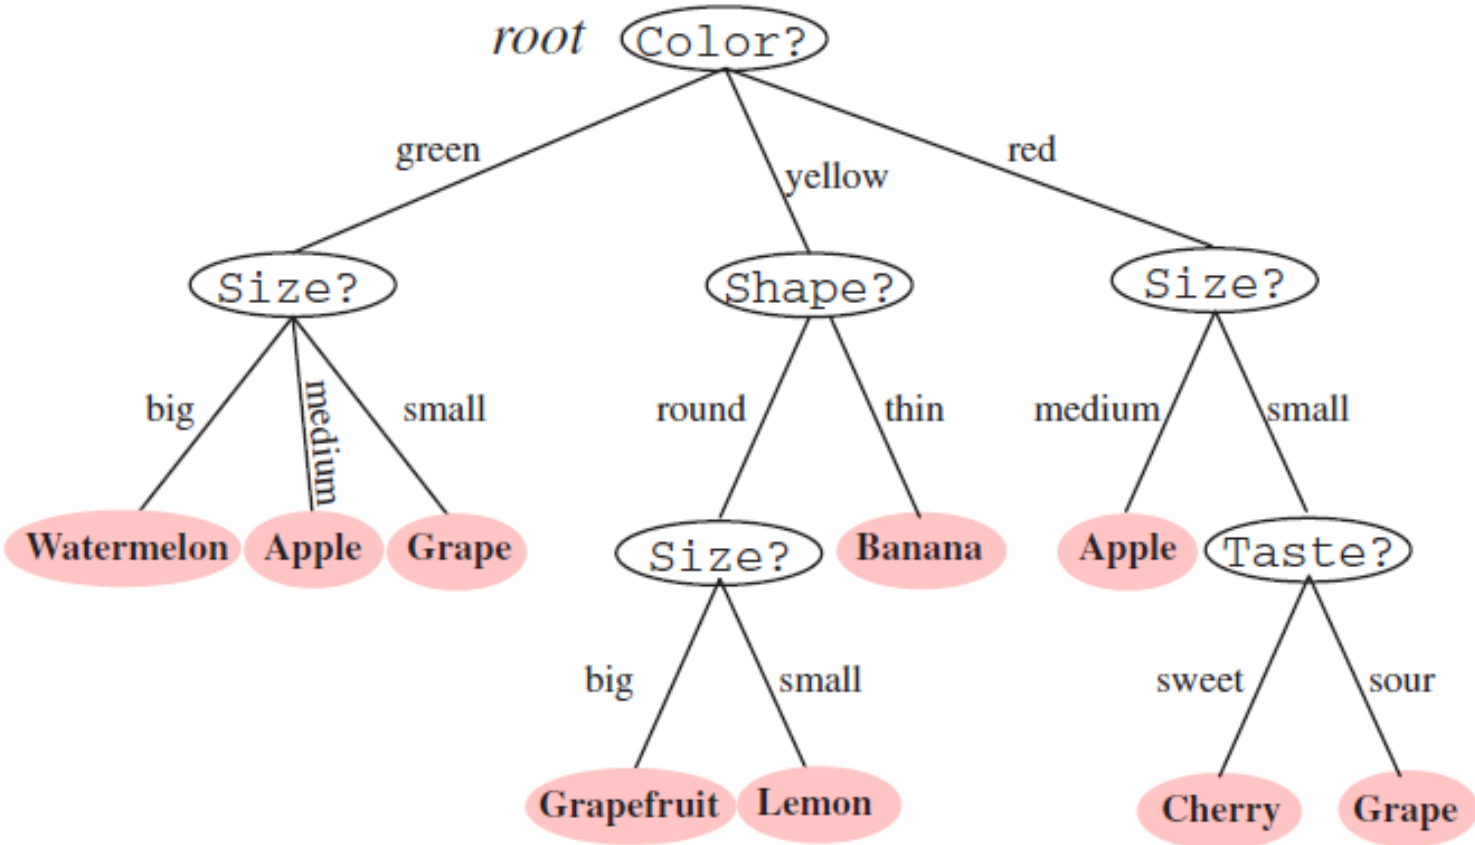

Arbres de décision : structure

- Données codées comme ensemble d'attributs (ex : attributs d'un fruit = couleur, taille forme, goût...)
- Noeud de décision associé à un test ou une question sur un des attributs
- Branches qui représentent les valeurs possibles de l'attribut testé ou des réponses aux questions
- Noeud terminal ou feuille définissant la prédiction

Arbres de décision et partition

- Les questions découpent (partitionnent) l'espace des données à chaque étape
- Le noeud terminal code un élément de la partition
- Toutes les données codées par le noeud terminal ont la même prédiction

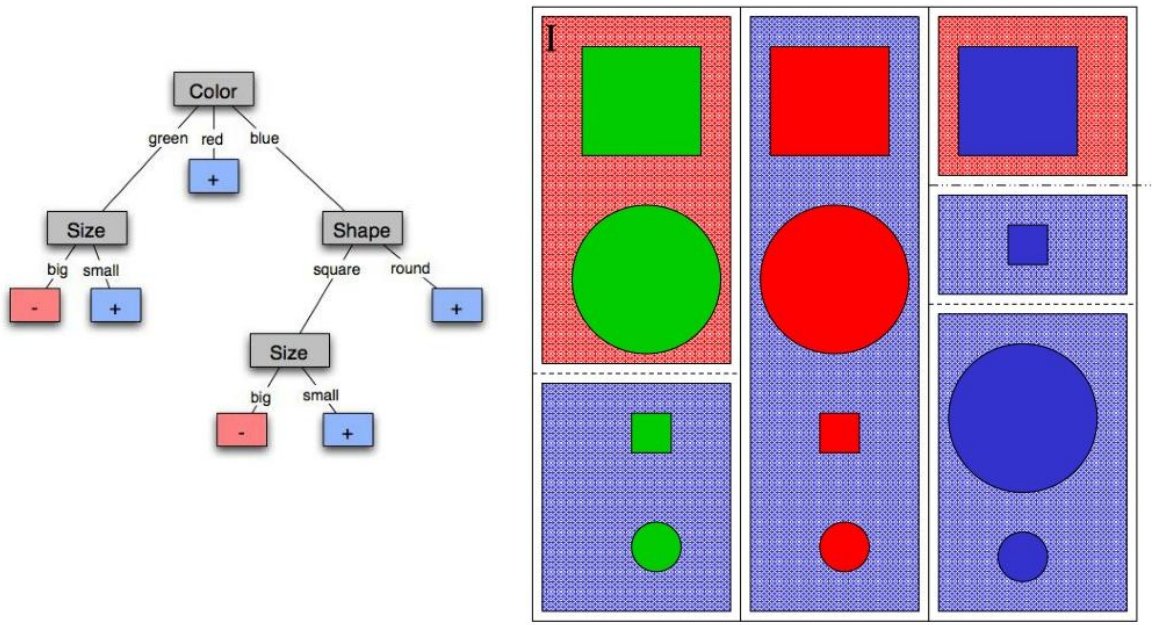

Figure 1 – Partition sur des données symboliques. Les questions portent sur la valeur d'un attribut discret.

Arbres de décision et partition

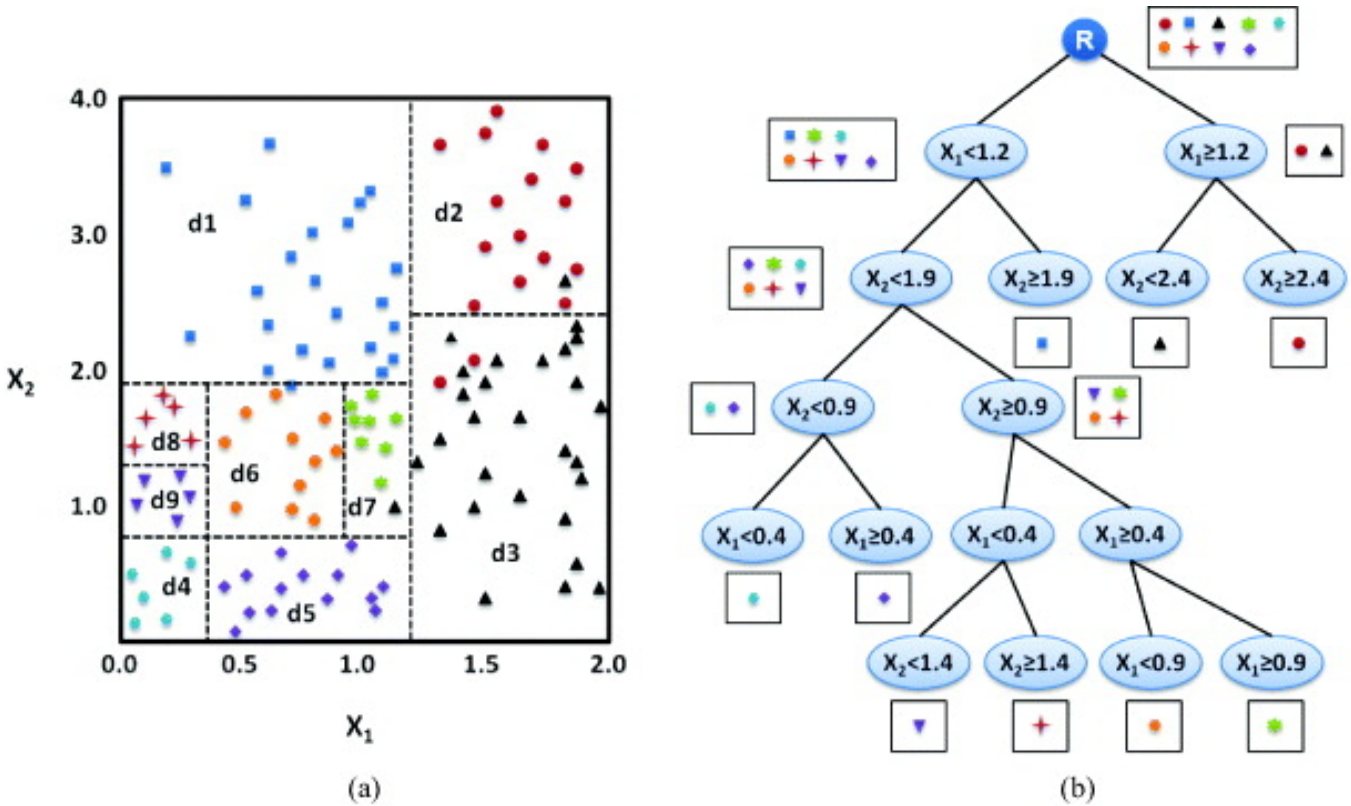

Figure 2 – Prédiction multi-classe. Les questions sont des tests comparant la valeur d'une dimension à un seuil.

Arbres de décision

Quelles questions se poser pour construire un arbre ?

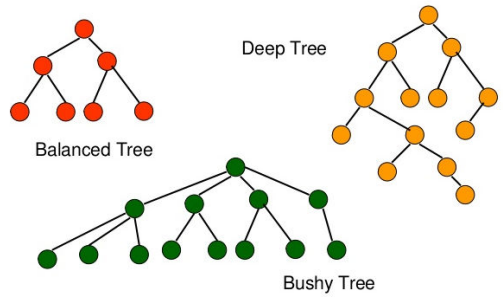

Questions globales :

- Quelle structure choisir ? (profond, équilibré,...) ?
- Combien de découpages par noeud ? (binaire, plus)
- Quand s'arrêter de découper ?

Questions locales :

- Quel attribut choisir, et quel test lui appliquer ?
- Si l'arbre est trop grand, comment l'élaguer ?
- Si une feuille n'est pas pure, quelle classe attribuer ?

Arbres de décision : apprentissage

Soit $D = \{(x_j, y_j)\}_{j \leq N}$ un ensemble d'apprentissage où chaque donnée est caractérisée par ensemble d'attributs $x_j = \{a_i^j\}_{1 \leq j \leq M}$, avec a_i^j à valeurs numériques ou symboliques.

Principes pour construire l'arbre de décision compatible avec D :

- « Rasoir d'Occam » : trouver l'hypothèse explicative la plus simple possible (principe local)
- « Minimum Description Length » : trouver l'ensemble des hypothèses qui produit le plus petit nombre d'opérations (principe global)

Recherche optimale impossible (problème NP-complet) [10]
➠ Heuristique assurant un arbre cohérent avec les données d'apprentissage.

Arbres de décision : algorithme élémentaire

Principe général

Construction incrémentale d'un arbre.

Trois étapes

1. Décider si un noeud est **terminal**
2. Si un noeud n'est pas terminal, choisir un attribut, un test et des **branches** possibles
3. Si un noeud est terminal, lui associer une **prédiction** (une classe, une valeur, etc.)

Remarques

- il est courant de n'utiliser que des tests *binaires* (vrai/faux).
- il existe des formulations non récursives plus globales [8].

Arbres de décision : Formulation récursive

Fonction `Construire_arbre`(D)

`Si` les données de D ont des valeurs *homogènes* (critère d'arrêt)

- créer une feuille et une prédiction estimée avec la valeur des données

`Sinon`

- choisir un attribut a_i et un test T ayant J réponses possibles pour créer un nouveau noeud et une question associée
- la question partitionne D en J sous-ensembles $\{D_j\}_{j=1...J}$ associés à chaque branche j
- répéter `Construire_arbre`(D_j) pour chaque branche j

Arbres de décision : comment choisir la bonne question ?

- A chaque noeud non homogène, on associe une question = attribut + test sur J valeurs.
- On dispose d'un critère d'hétérogénéité $I(D)$ caractérisant une population de données D.
- À chaque noeud, on choisit de T^* maximisant le gain en homogénéité :

$$T^* = \arg\max_T Gain(D, T)$$

où $Gain(D, T) = I(D) - \sum_j p(D_j|D, T) I(D_j)$
et $p(D_j|D, T) = |D_j|/|D|$ est la proportion de données dans D sélectionnées par la branche j

Remarque : En pratique, le nombre de tests à évaluer peut être très grand. La recherche du arg max peut faire intervenir des heuristiques sous-optimales.

Arbres de décision : critères d'homogénéité

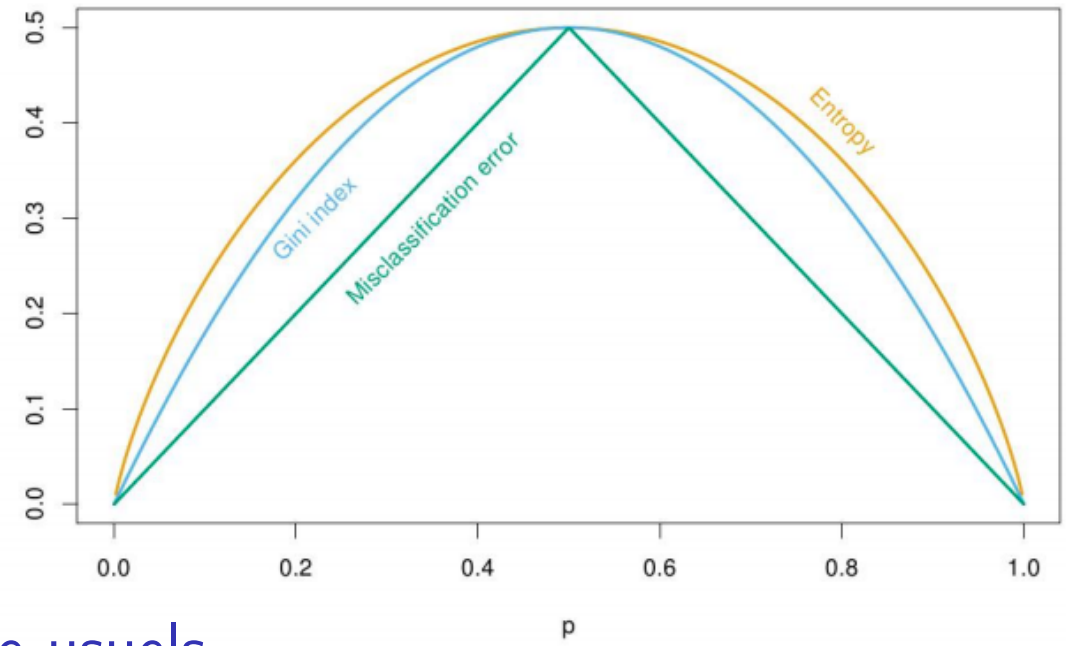

Trois critère usuels

- Entropie : $I(D) = -\sum_k p_k(D) log_2(p_k(D))$
- Indice de Gini : $I(D) = \sum_k p_k(D)(1 - p_k(D))$
- Indice d'erreur : $I(D) = 1 - max_k(p_k(D))$

où $p_k(D) = N_k(D)/|D|$ est la probabilité d'avoir une donnée de classe k dans l'ensemble D.

Quand s'arrêter ?

Critères structuraux

- Profondeur maximale
- Nombre de feuilles minimal

Critères statistiques

- Indice d'homogénéité minimal
- Nombre minimal de données en chaque noeud (avant ou après répartition)

Que prédire ?

On exploite la population de données associée à chaque feuille de l'arbre.

Classification

- Classe la plus probable
- Distribution de classes

Régression

- Moyenne, médiane de la population

Exemple simulé

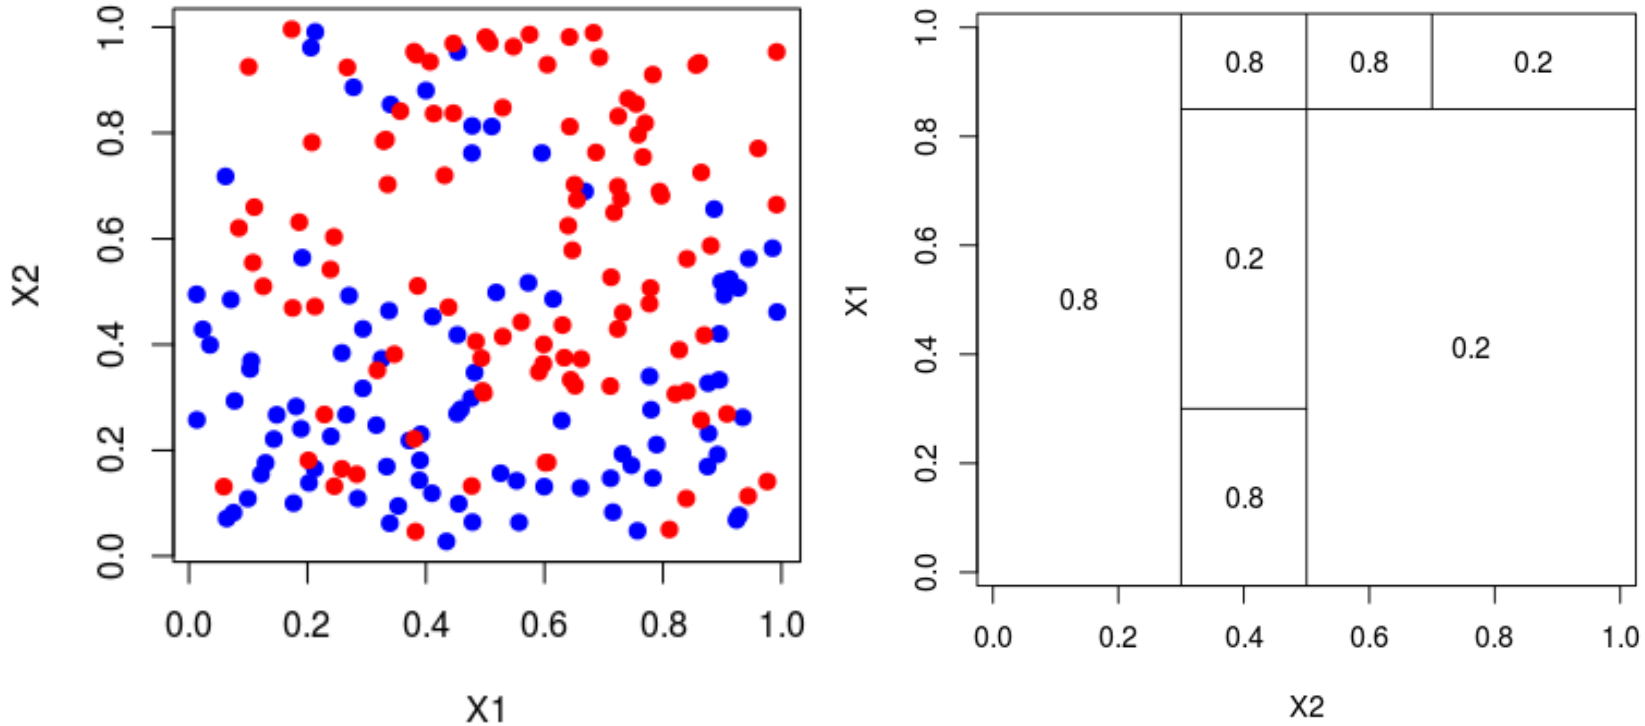

Figure 3 – Distribution simulée et arbre théorique optimal.

Exemple simulé : Recherche du meilleur test

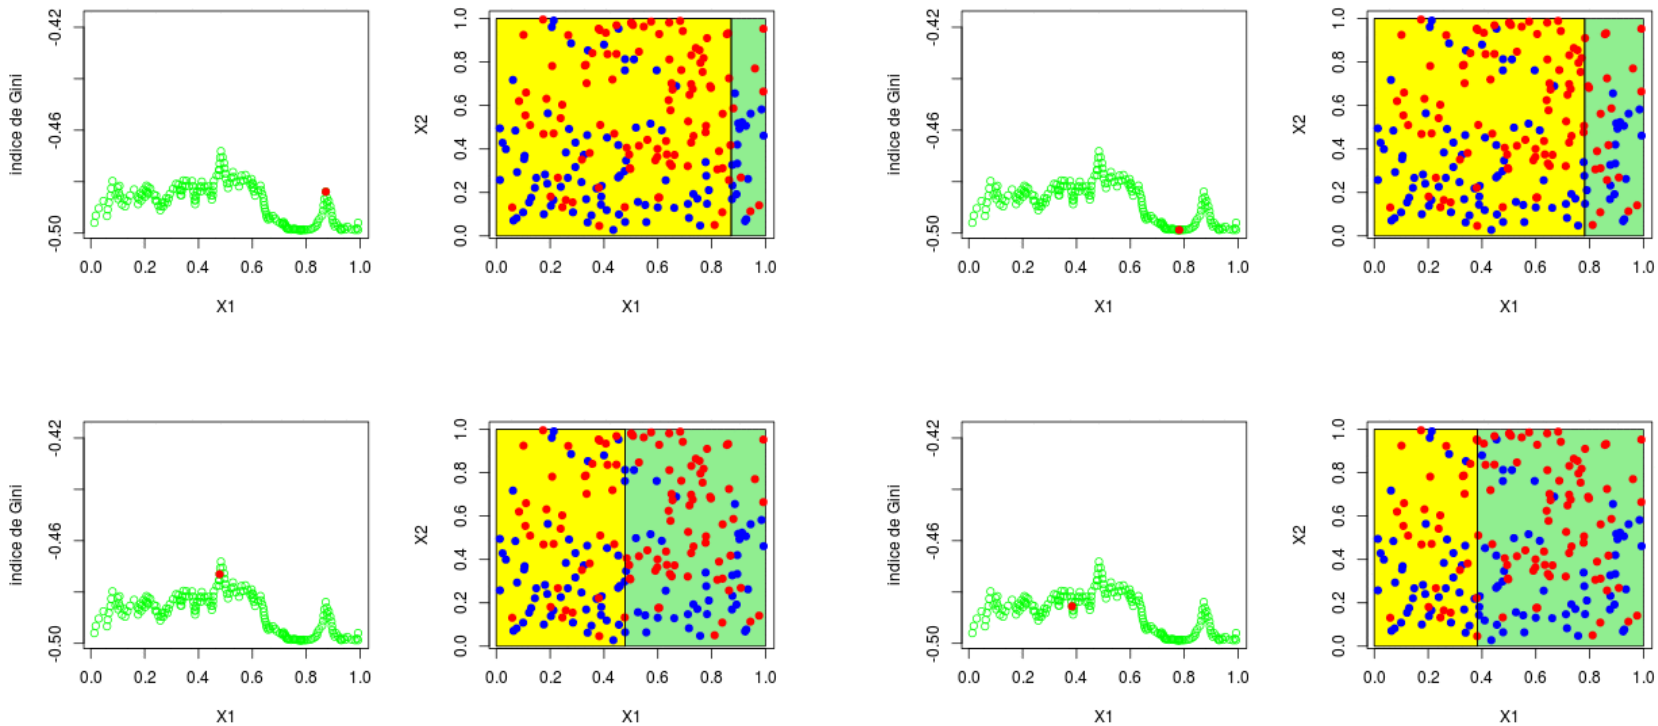

Figure 4 – Recherche sur premier axe avec indice de Gini.

Exemple simulé : Recherche du meilleur test

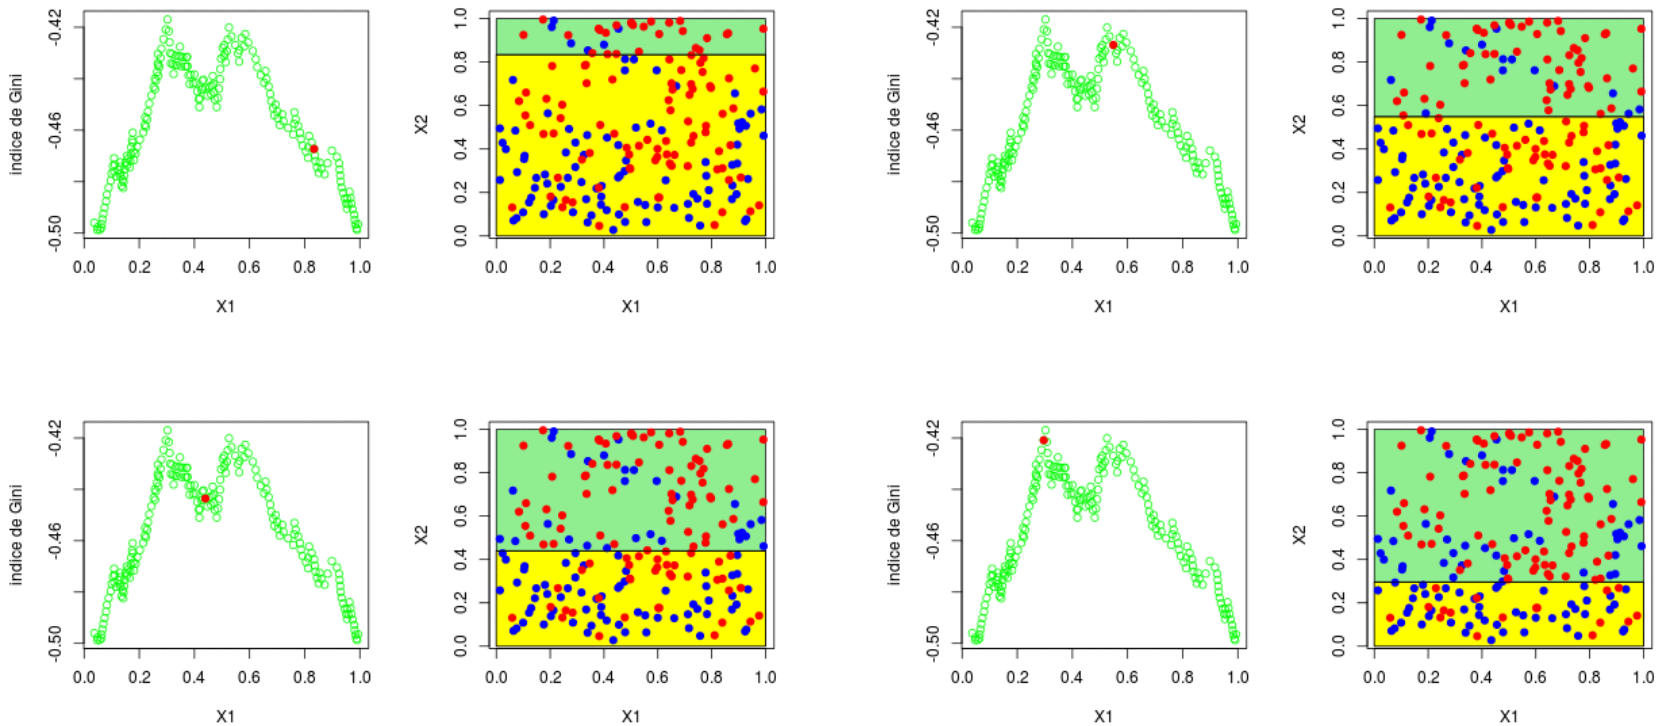

Figure 5 – Recherche sur deuxième axe avec indice de Gini.

Exemple simulé : résultat (indice de Gini)

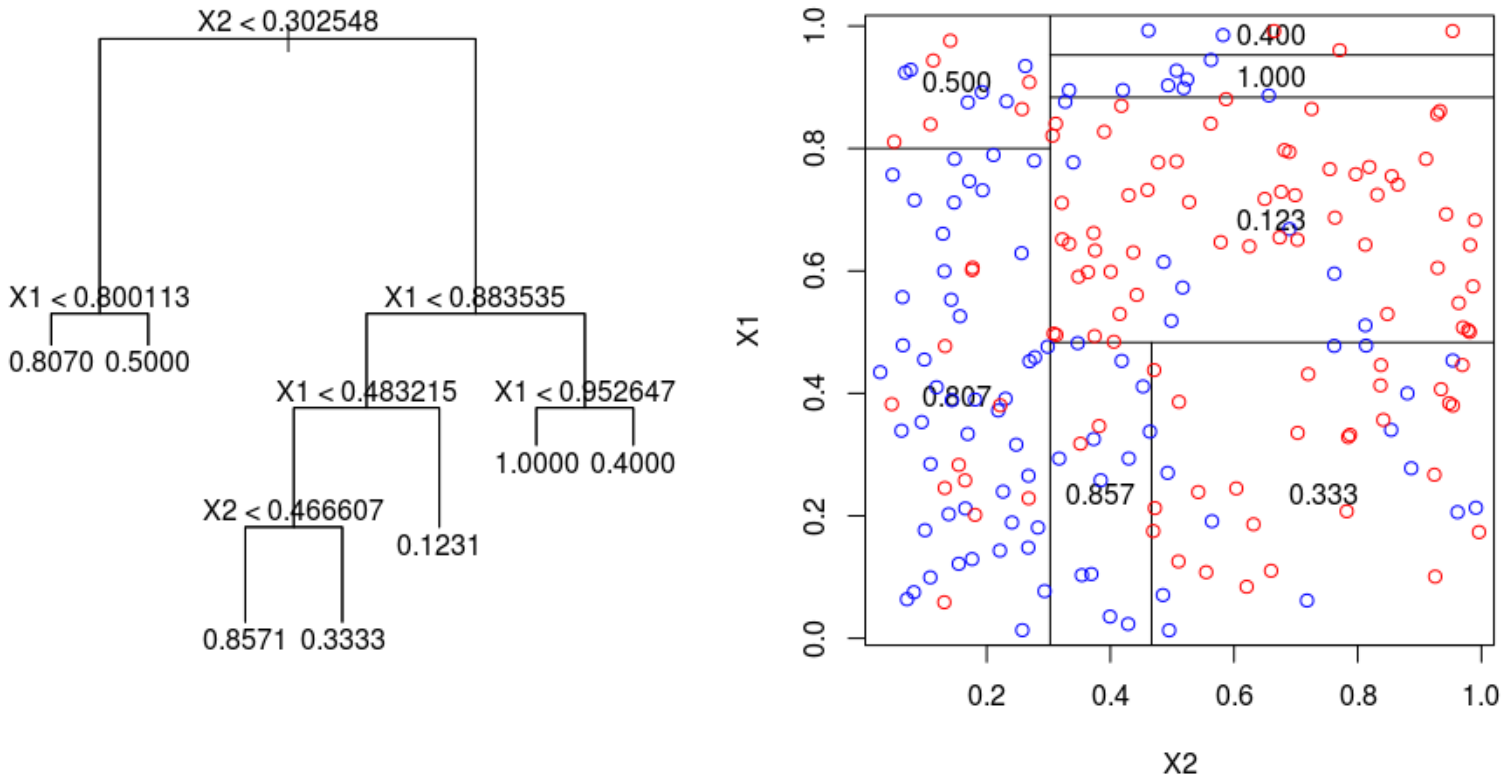

Figure 6 – Arbre et partition finale avec probabilité de classe bleue pour chaque région.

Arbres de décision : comportement statistique

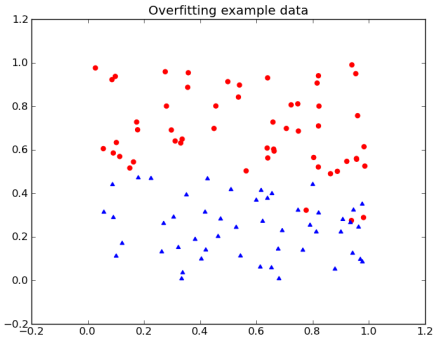

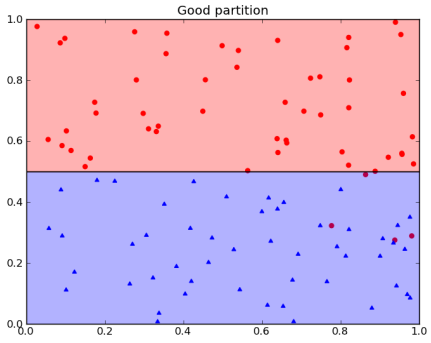

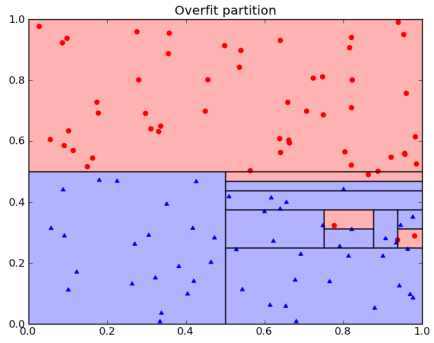

Sur-apprentissage

- Un arbre trop précis risque de mal généraliser (cf. k-NN)
- Les arbres peuvent être mal équilibrés
- On peut utiliser des techniques d'élagage (« pruning ») pour améliorer a posteriori la qualité des arbres

Arbres de décision : comportement statistique

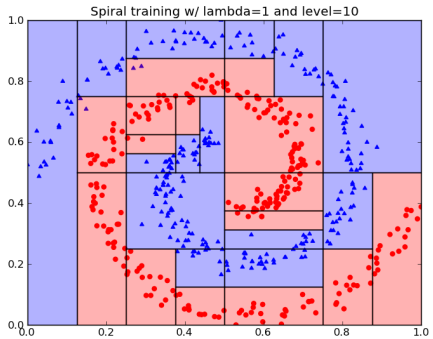

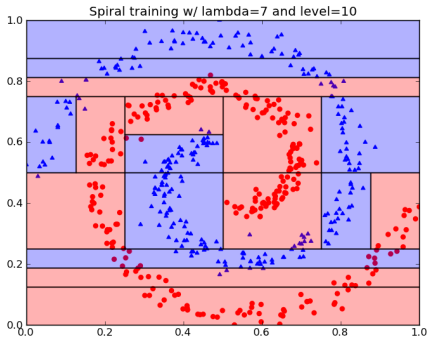

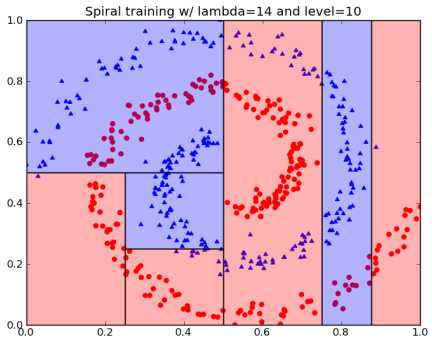

La complexité peut être contrôlée

- en limitant la profondeur
- en minorant le gain en homogénéité
- en ajoutant une pénalisation de complexité dans le coût
- en garantissant une bonne estimation des coûts (par ex. un nombre minimal d'échantillons par noeud)

Arbres de décision : Résumé

Points clés des arbres de décision

+ Interprétabilité
+ Apprentissage et classification rapides et efficaces, y compris en grande dimension.
- Tendance au surapprentissage (mais moyen de contrôle de la complexité)
- Sensibilité au bruit et aux points aberrants, instabilité

Utilisations

+ Classification ou régression...
+ Capable de traiter des données numériques, mais aussi symboliques

Méthodes ensemblistes

Définition

- Méthodes agrégeant des *ensembles* de classifieurs ;
- Produire une variété de classifieurs : en échantillonnant différemment les données, en modifiant les structures de classifieurs ;
- Classe finale = fusion des prédictions.

Principe

- *L'union fait la force* : tirer parti de plusieurs classifieurs peu performants (« faibles ») pour construire un classifieur performant (« fort »)
  ➠ *Réduit la variance* d'apprentissage et moyenne les erreurs

Méthodes ensemblistes

Deux grandes approches : bagging et boosting

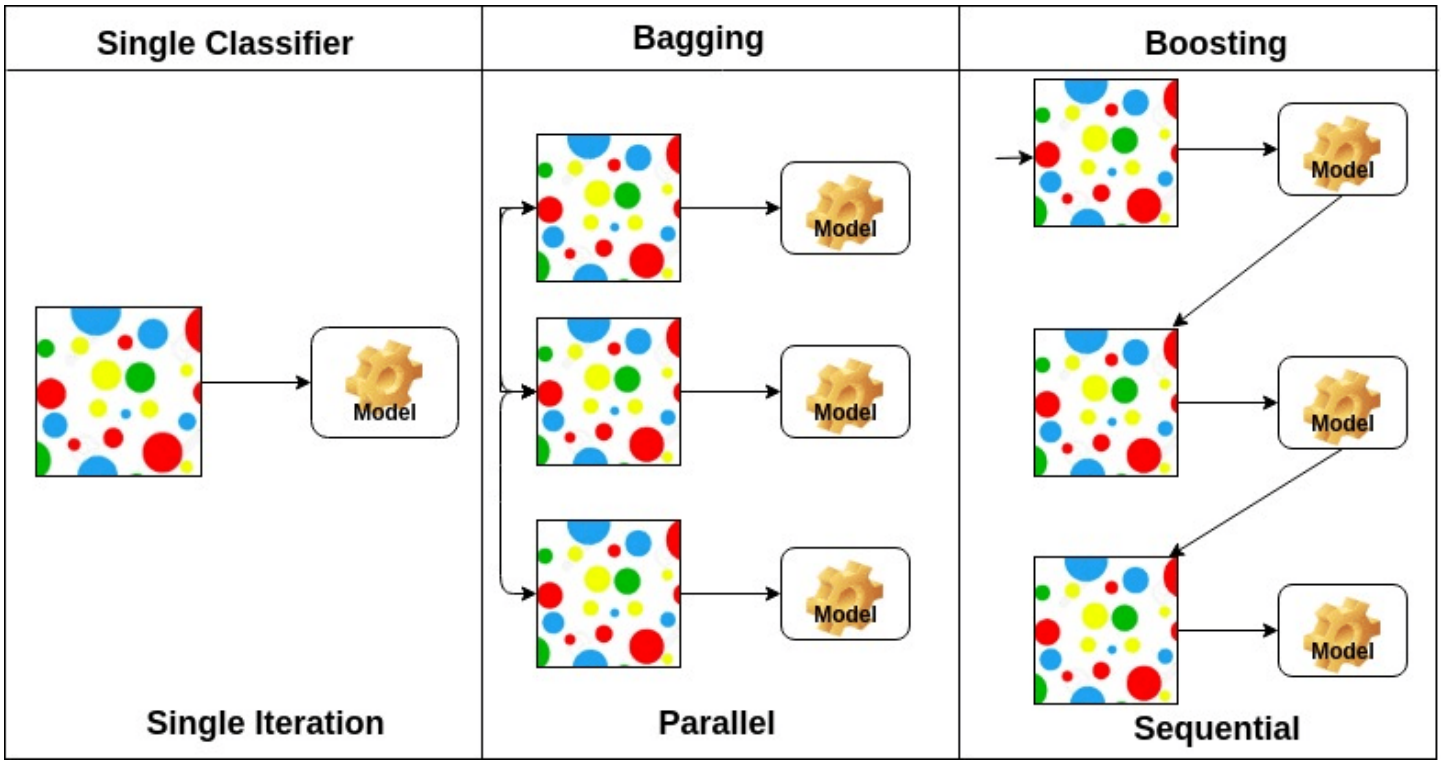

Bagging [1]

Génération de jeux de données multiples

- Construction de $\tilde{X}_1, ..., \tilde{X}_K$ par tirage avec remise sur X.
- $\tilde{X}_k$ similaires, mais pas trop (proba d'un exemple de ne pas être sélectionné $p = (1 - 1/N)^N$. Quand $N \to \infty$, $p \to 0.3679$.)
- Entraîner K fois le même algorithme f_k (arbre, réseau de neurones, SVM..) sur chaque $\tilde{X}_k$ et agréger par vote majoritaire ou moyenne $f(x) = \frac{1}{K} \sum f_k(x)$

Conséquence

- Chaque classifieur commet des erreurs différentes, liées à $\tilde{X}_k$ $\rightarrow$ l'agrégat a une plus faible variance d'apprentissage
- Méthode pour *régulariser* le processus de prédiction.

Bagging

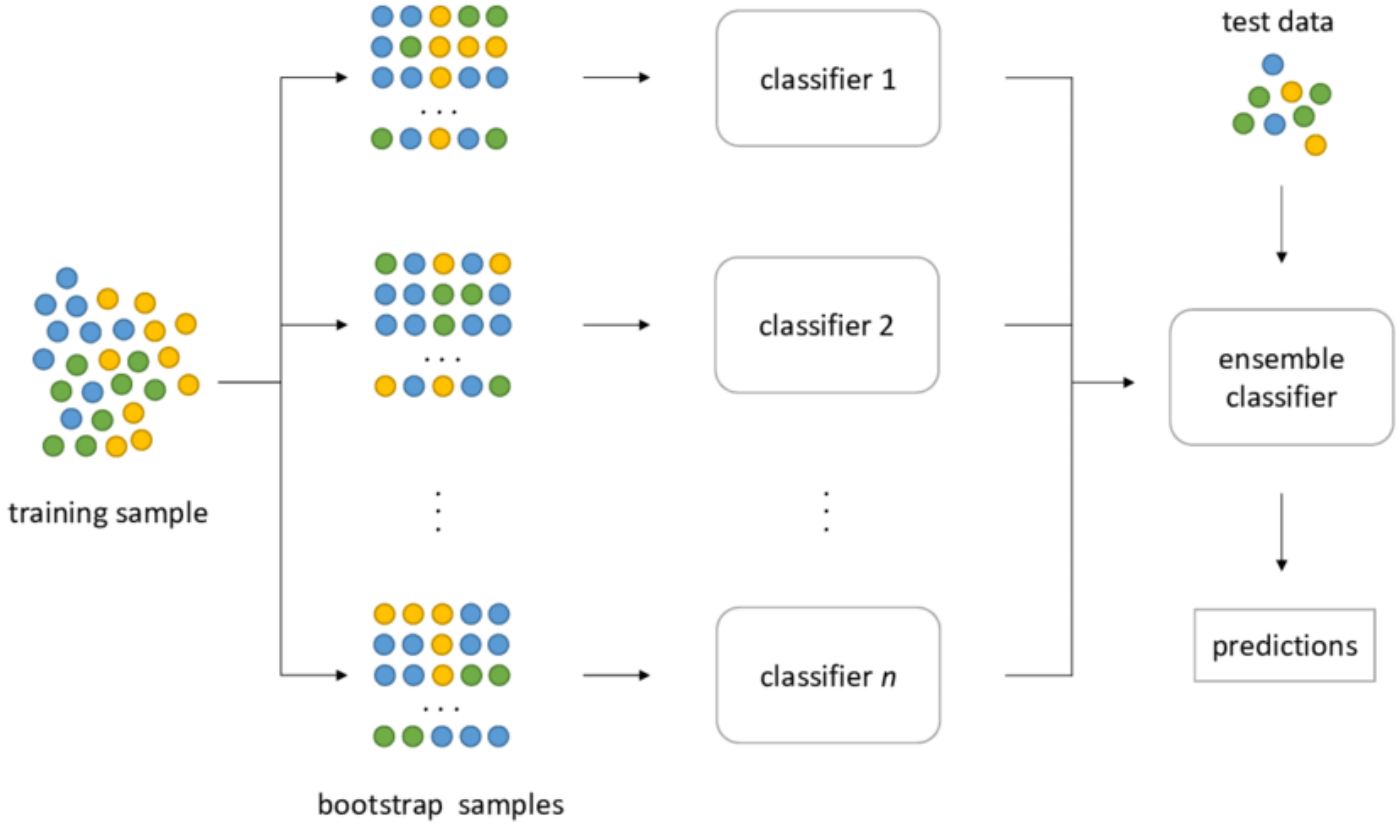
test data
classifier 1
classifier 2
classifier n
ensemble classifier
predictions
training sample
bootstrap samples

Random Forests [2]

Forêts aléatoires ou *Random forests*

➠ Combiner hasard et bagging pour construire un ensemble d'arbres de décision encore plus varié (=forêt)

- La partie calculatoire des arbres de décision est la construction incrémentale de leur structure (meilleure paire attribut & test)
- Structure = paramètre de contrôle des arbres (profondeur max, critère de pureté des noeuds, nombre d'échantillons par noeud...) + aléatoire sur attributs/données/tests

Random Forests

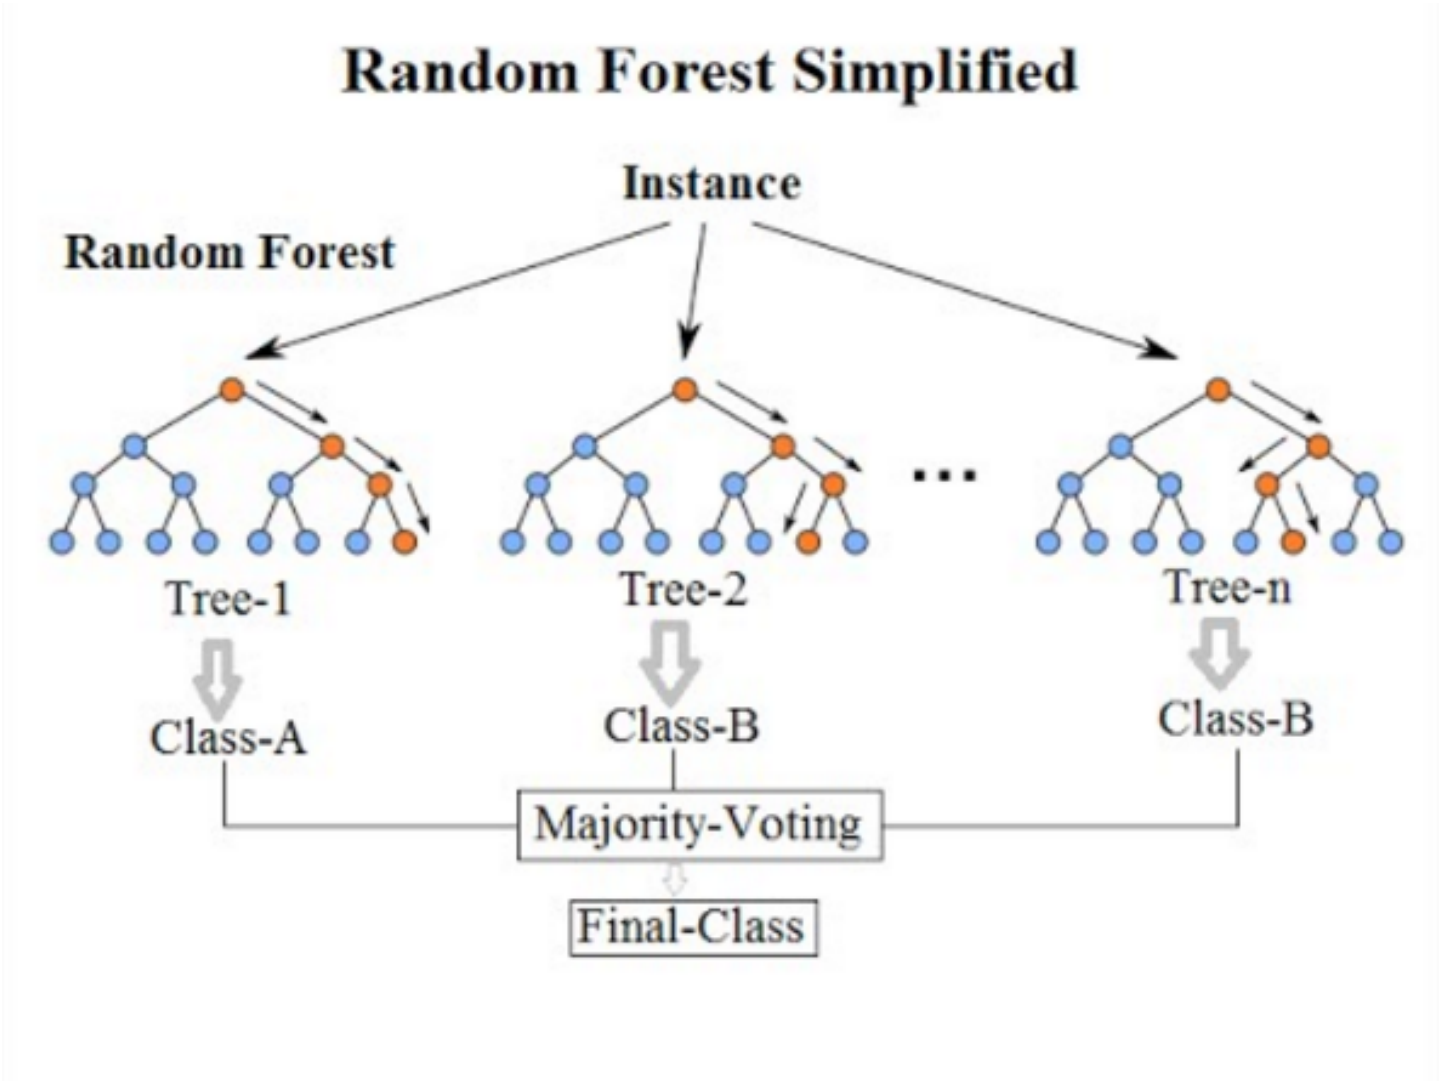

Random Forests

Forêts aléatoires ou *Random forests*

Algorithme :

POUR $k = 1 \dots K$:

- Bagging : tirage de $\tilde{X}_k$ de même taille que X
- Tirage (avec remise) de q attributs A_i parmi les M possibles
- Construction de l'arbre G_k avec des seuils aléatoires
- Construction de f_k la fonction de décision de G_k dont les feuilles sont remplies avec $\tilde{X}_k$

Agrégation :

- $f(x) = \frac{1}{K} \sum f_k(x)$ (régression)
- $f(x) =$ Vote majoritaire$(f_1(x), \dots, f_K(x))$

Biais et variance

Exemple de la régression

$$y = f(\mathrm{x}) + \epsilon$$

Il y a deux sources d'aléatoire :

- Le bruit : ϵ (un même x peut produire différents y)
- L'échantillonnage des données d'apprentissage : D

On définit pour un prédicteur appris $\hat{f}_D(\mathrm{x})$:

Erreur écart quadratique moyen entre prédiction et valeur idéale

Biais erreur de la prédiction moyenne par rapport à la valeur idéale

Variance écart quadratique moyen entre prédiction et prédiction moyenne

Biais et variance

Compromis biais variance

L'erreur pour un x donné peut se décomposer en :

$$\begin{aligned}\mathrm{Err}(\mathrm{x}) &= E_D[(y - \hat{f}_D(\mathrm{x}))^2] \\ &= \underbrace{\epsilon^2}_{\text{bruit}^2} + \underbrace{(E_D[\hat{f}_D(\mathrm{x})] - y)^2}_{\text{biais}^2} + \underbrace{E_D[(E_D[\hat{f}_D(\mathrm{x})] - \hat{f}_D(\mathrm{x}))^2]}_{\text{variance}}\end{aligned}$$

L'origine de l'erreur de généralisation est double, mais les deux termes sont difficiles à contrôler individuellement.

Rem : pour la classification, une telle décomposition est plus difficile à obtenir, mais les comportements sont comparables.

Biais et variance

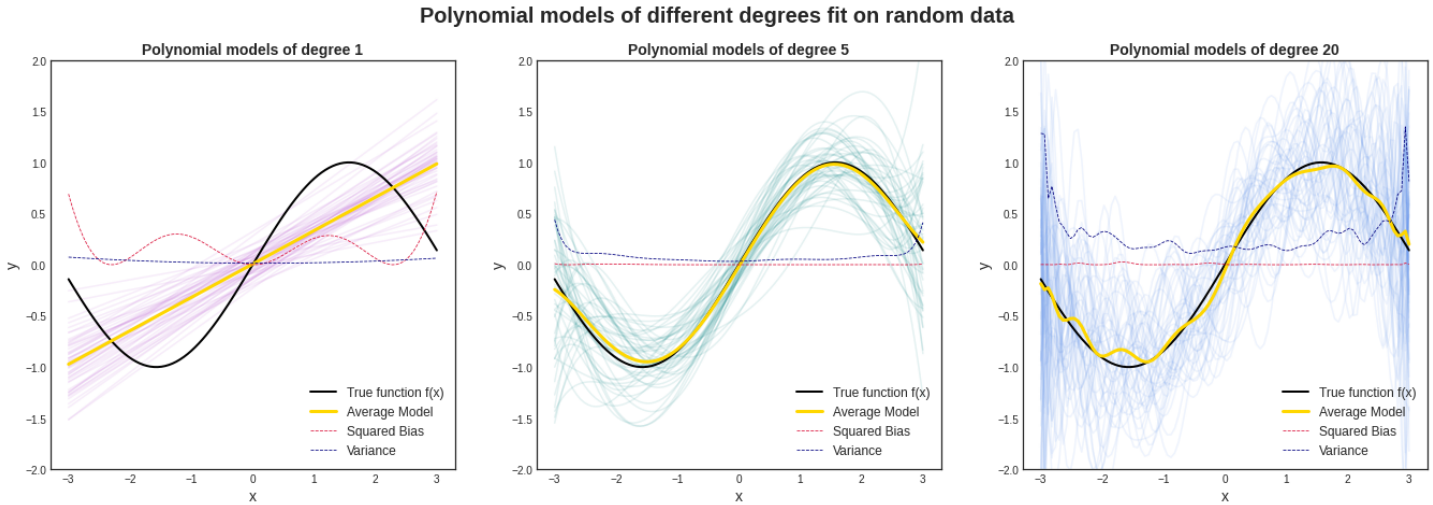

Figure 7 – Simulation d'une régression pour 50 échantillons et polynomes de degrés 1,5,20.

- Degré 1 : variance faible, mais biais important
- Degré 5 : variance et biais faibles
- Degré 20 : variance importante et biais très faible

Intérêt des approches ensemblistes

On introduit une source d'aléatoire supplémentaire : choix des splits, du sous ensemble de variables, etc.
Lorsque les prédicteurs individuels sont sans biais (c'est le cas avec les arbres), la variance du prédicteur ensembliste est :

$$\mathrm{var}\left(\hat{f}_D(\mathrm{x})\right) = \rho\sigma^2 + \frac{1-\rho}{K}\sigma^2$$

σ variance d'un prédicteur individuel et ρ corrélation entre deux prédicteurs.
On voit que l'on a intérêt à construire des prédicteurs individuels indépendants ($\rho \approx 0$), et en grand nombre (K grand).

Random Forests : Résumé

Points clés des forêts aléatoires

- \+ Bonnes performances
- \+ Arbres plus décorrélés que par simple bagging
- \+ Grandes dimensions
- \+ Robustesse
- \- Temps d'entraînement (mais aisément parallélisable).

Utilisation

- Choix d'une faible profondeur (2 à 5), autres hyper-paramètres à estimer par validation croisée
- Classification et régression
- Données numériques et symboliques

Boosting [5]

Principe

- $X = \{(x_i, y_i)\}_{i=1}^{N}$ un ensemble de données où $y_i \in \{-1, 1\}$
- H un ensemble ou une famille de classifieurs $f \mapsto -1, 1$, pas forcément performants ➞ appelés *weak learners*

Objectif du boosting :

- Construire un classifieur performant $F(x) = \sum_{k=1}^{K} \alpha_k f_k(x)$ ➞ appelé *strong learner*
- Moyenne *pondérée* des *weak learners*

➠ Comment trouver les poids ?

Boosting

AdaBoost

- Adaboost = « Adaptive boosting algorithm », algorithme minimisant l'erreur globale de F de manière itérative
- Principe : à chaque itération k, modifier F^k de manière à *donner plus de poids aux données difficiles* (mal-classées) qui permettent de corriger les erreurs commises par F^{k-1}

Boosting

AdaBoost : algorithme

Initialiser les poids liés aux données :
$d^0 \leftarrow (\frac{1}{K}, \frac{1}{K}, \ldots, \frac{1}{K})$
POUR $t = 1 \ldots K$:

- Entraîner f_k sur les données X pondérées par d^{k-1}
  $(f_k = \arg\min_f \sum_i d_i^{k-1}[y_i \neq f(x_i)])$
- Prédire $\hat{y} = y^i \leftarrow f_k(x_i), \forall i$
- Calculer l'erreur pondérée $\epsilon^k \leftarrow \sum_i d_i^{k-1}[y_i \neq \hat{y}_i]$
- Calculer les paramètres adaptatifs $\alpha^k \leftarrow \frac{1}{2} \log\left(\frac{1-\epsilon^k}{\epsilon^k}\right)$
- Re-pondérer les données $d^k = d_i^k \leftarrow d_i^{k-1} \exp\left(-\alpha^k y_i \hat{y}_i\right)$

Classifieur (pondéré) final : $F(x) = \mathrm{sgn}\left(\sum_{k=1}^{K} \alpha_k f_k(x)\right)$

Boosting

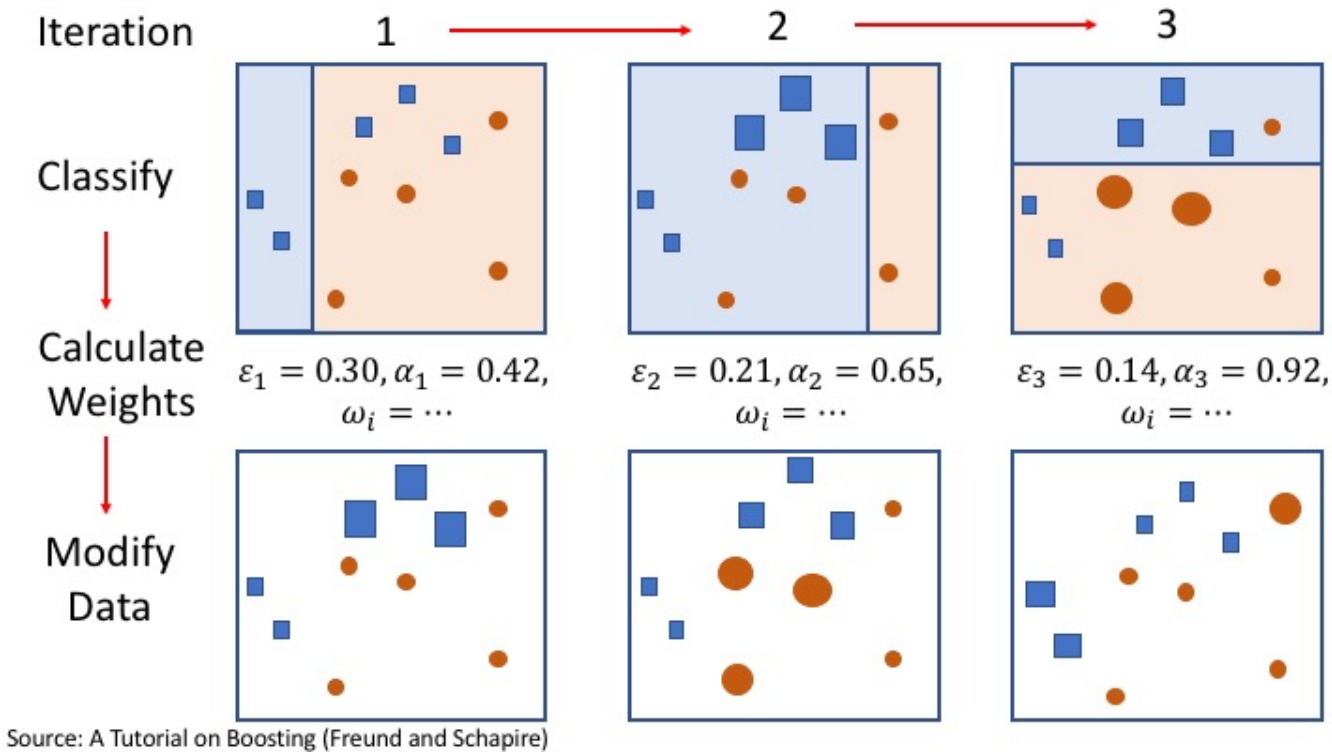

Figure 8 – Apprentissage séquentiel des classifieurs et des pondérations.

Boosting

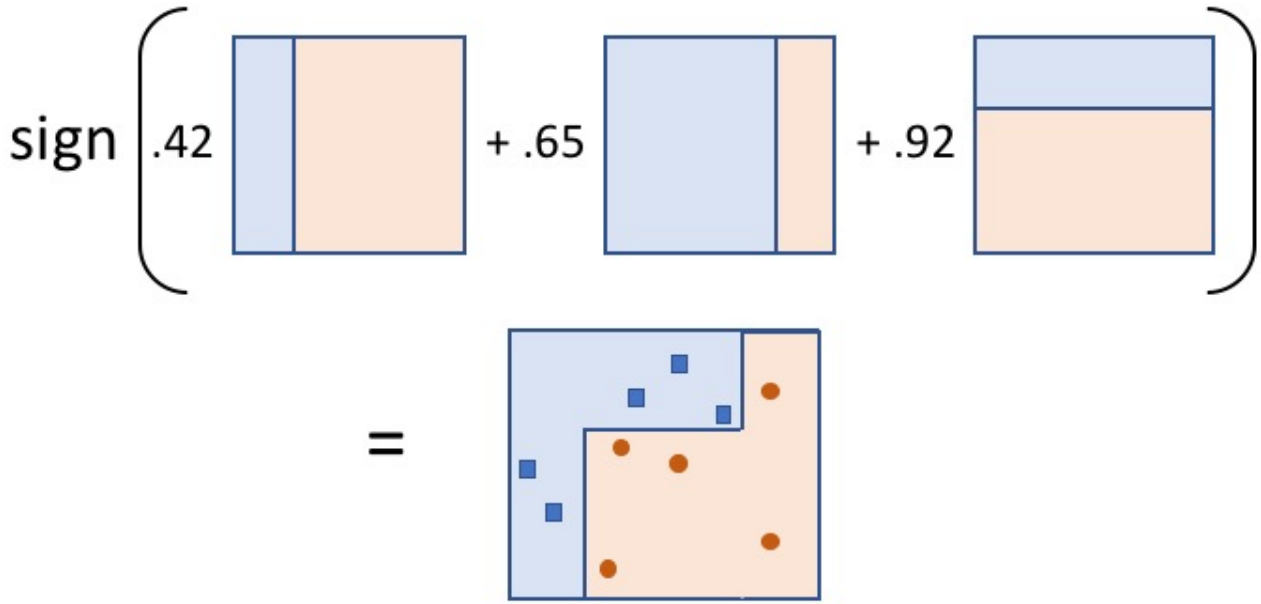

Source: A Tutorial on Boosting (Freund and Schapire)

Figure 9 – Classifieur final.

Gradient Boosting [6, 7]

Gradient Boosting

Variante : version additive pas-à-pas

- $X = \{(x_i, y_i)\}_{i=1}^N$ un ensemble de données où $y_i \in \{-1, 1\}$
- H un ensemble de classifieurs $f \mapsto -1, 1$, pas forcément performants → appelés *weak learners*

Objectif du gradient boosting :

- Construire itérativement un classifieur performant $F_T(x) = \sum_{t=1}^T \alpha_t f_t(x) = F_{T-1}(x) + \alpha_T f_T(x)$ où f_t est l'un des weak learners h.
- Il s'agit à chaque étape de minimiser le risque empirique : $\mathcal{L}(F_T) = \sum_{n=1}^N l(y_n, F_T(x_n))$ où l est un coût (*loss*)

Gradient Boosting

Coûts

- Adaboost → gradient boost avec fonction de coût $l(y, f(x)) = \exp(-y.f(x))$
- Adaboost peut être vu comme la construction itérative d'un classifieur optimal par minimisation du risque empirique à chaque pas.
- Cadre plus général : d'autres pénalités sont possibles :
  - LogitBoost : $l(y, f(x)) = \log_2(1 + \exp[-2y.f(x)])$
  - L_2 Boost : $l(y, f(x)) = (y - f(x))^2/2$
  - DoomII : $l(y, f(x)) = 1 - \tanh(y.f(x))$
  - Savage : $l(y, f(x)) = \frac{1}{(1+\exp(2y.f(x)))^2}$
- DoomII et Savage sont non-convexes → plus robustes aux données bruitées

Gradient Boosting

Pourquoi *Gradient* Boosting ?

- Chaque étape minimise le risque empirique :
  $\mathcal{L}(F_T) = \sum_{n=1}^{N} l(y_n, F_T(x_n))$ où l est un coût (*loss*)
- Lors de la variante additive d'adaboost, $\alpha_T f_T(x)$ peut donc être vu comme le *weak learner* qui approxime le mieux le pas d'une descente de gradient dans l'espaces des fonctions de classification
- Une version exacte de la descente de gradient donne les Gradient Boosting Models :
  $F_T(x) = F_{T-1}(x) + \alpha_T \sum_{i=1}^{N} \nabla_{F_{T-1}} l(y_i, f_{T-1}(x_i))$

Boosting : Résumé

Points clés du boosting

- Agrégation adaptative de classifieurs moyens
- \+ Résultats théoriques sur la convergence et l'optimalité du classifieur final
- \+ Très efficace (améliore n'importe quel ensemble de classifieurs)
- \+ Assez facile à mettre en oeuvre (moins vrai pour Gradient Boosting)
- \- Sensibilité aux données aberrantes, surapprentissage

Utilisations

- Choix du *weak learner* : ne doit pas être trop bon, sinon surapprentissage
- Choix de la pénalité en fonction du bruit des données
- Variantes pour la classification et la régression

Cours n°2 : Arbres de décision et méthodes ensemblistes

Notions phares du jour

- Arbres de décision (vote, homogénéité)
- Aggrégation de classifieurs
- Bagging, Random Forests
- Boosting, GradientBoost

Concepts généraux

- Classification / régression
- Bagging et randomisation (Forêts aléatoires)
- Construction adaptative à partir de *weak learners* et optimisation dans l'espace des classifieurs (Boosting)

Références I

[1] Leo Breiman.
Bagging predictors.
Machine learning, 24(2) :123–140, 1996.

[2] Leo Breiman.
Random forests.
Machine learning, 45(1) :5–32, 2001.

[3] Leo Breiman, Jerome H Friedman, Richard A Olshen, and Charles J Stone.
Classification and regression trees.
Routledge, 2017.

[4] Tianqi Chen and Carlos Guestrin.
Xgboost : A scalable tree boosting system.
In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, pages 785–794, 2016.

[5] Yoav Freund and Robert E Schapire.
A decision-theoretic generalization of on-line learning and an application to boosting.
Journal of computer and system sciences, 55(1) :119–139, 1997.

[6] Jerome H Friedman.
Greedy function approximation : a gradient boosting machine.
Annals of statistics, pages 1189–1232, 2001.

[7] Jerome H Friedman.
Stochastic gradient boosting.
Computational statistics & data analysis, 38(4) :367–378, 2002.

[8] Donald Geman and Bruno Jedynak.
Model-based classification trees.
IEEE Transactions on Information Theory, 47(3) :1075–1082, 2001.

Références II

[9] Trevor Hastie, Robert Tibshirani, and Jerome Friedman.
The elements of statistical learning.
Springer, 2009.

[10] Hyafil Laurent and Ronald L Rivest.
Constructing optimal binary decision trees is np-complete.
Information processing letters, 5(1) :15–17, 1976.